

追索为什么? 地球系统科学中的因果推理

苏建宾¹, 陈都鑫², 郑东海¹, 苏阳³, 李新^{1*}

1. 中国科学院青藏高原研究所, 青藏高原地球系统与资源环境国家重点实验室, 国家青藏高原科学数据中心, 北京 100101;

2. 东南大学数学学院, 南京 210096;

3. 中国科学院西北生态环境资源研究院, 兰州 730000

* 通讯作者, E-mail: xinli@itpcas.ac.cn

收稿日期: 2023-01-05; 收修改稿日期: 2023-06-29; 接受日期: 2023-07-21; 网络版发表日期: 2023-09-04

国家自然科学基金项目(批准号: 41988101, 42101397)资助

摘要 地球大数据使人们以前所未有的维度和规模认识赖以生存的地球, 而挖掘隐藏在数据背后的因果关联是深入理解地球系统的关键。长期以来, 以相关为内核的统计方法都是地球系统科学的研究主流方法, 但相关并不等于因果, 特别是大数据导致“伪相关”的泛滥, 传统的相关和回归方法难以解释地球系统因果相关问题。随着因果理论和推理方法的完善, 特别是近年来因果发现和因果图模型的成熟, 因果推理在地球系统规律揭示、过程理解、假设检验和模型改进等多个研究方向展现出蓬勃的生命力。文章从因果关系的起源、内涵和发展入手, 概述了因果推理的主要研究框架和地球系统科学领域常用的因果推理方法, 回顾了因果推理在地球系统主要分支领域的应用, 探讨了地球系统科学领域因果推理实践面临的挑战和发展方向。在地球大数据背景下, 作为重要的大数据分析方法, 因果推理与物理模型和机器学习的互惠能够助力地球系统科学实现从模型驱动到机理与数据融合驱动研究范式的转换。展望未来, 结构化、规范化的因果理论能够为地球系统科学的因果认知筑基, 推动地球系统科学从单一领域的分散研究到地球系统综合理解的认识跃迁。

关键词 因果推理, 机器学习, 地球系统科学, 因果发现, 人工智能

1 引言

地球系统指由大气圈、水圈、陆圈(岩石圈、地幔、地核)和生物圈(包括人类)组成的有机整体。地球系统科学是以全球性、统一性的整体观、系统观和多时空尺度来研究组成地球系统的这些子系统之间相互联系和相互作用规律, 使得人类能更好地认识自身赖以生存的环境(Reichstein 等, 2019; Steffen 等, 2020)。

在地球系统相互作用规律的研究中, 相关与因果的共存与博弈从未停歇。早期, 因果关系被认为是客观规律的理论具现。在“现实世界简单性”前提下, 因果关系可以通过数值控制实验从地球系统关键变量的相互作用中抽取出来, 推动了地球系统科学理论发展, 也是构建各类地球物理模型的基础。在现代控制论和信息论的冲击下, 以相关为内核的统计分析(如回归、机器学习等)逐步成为地球系统科学的主流方法之一(徐道

中文引用格式: 苏建宾, 陈都鑫, 郑东海, 苏阳, 李新. 2023. 追索为什么? 地球系统科学中的因果推理. 中国科学: 地球科学, 53(10): 2199–2216, doi: [10.1360/SSTE-2023-0005](https://doi.org/10.1360/SSTE-2023-0005)

英文引用格式: Su J, Chen D, Zheng D, Su Y, Li X. 2023. The insight of why: Causal inference in Earth system science. Science China Earth Sciences, 66(10): 2169–2186, <https://doi.org/10.1007/s11430-023-1148-7>

一, 1986), 一定程度上解决了定量预测的难题(沈焕锋和张良培, 2023). 2008年, Anderson(2008)发表了“相关性取代因果关系”的观点, 将相关与因果的博弈推向风口浪尖, 引发了大数据时代关于相关性与因果关系的激烈争论(Succi和Coveney, 2019).

事实上, 在明确因果定义前, 相关和因果在很长一段时间是交互使用的, 但二者存在本质的不同. 通常而言, 相关表示一般的关联关系, 而因果则更加倾向于变量间的依存关系(Altman和Krzewinski, 2015). 存在因果关联的变量必然是相关的, 但相关并不一定代表因果(Aslam, 2015). 大数据时代的到来为科学研究带来了极大的便利, 但也导致了“伪相关”的泛滥(Calude和Longo, 2017), 特别是在高维度和强非线性的地球系统中, 变量间的“伪相关”十分普遍(Runge等, 2019a), 为基于传统相关性方法的研究埋下了隐患(Nearing等, 2020). 此外, 受混淆因素和隐变量的影响, 部分基于相关性的推论很难获得合理的解释(Peng和Susan, 2022). 例如, 在地球系统科学研究中, 以相关性为内核的机器学习模型, 其底层逻辑和结果的可解释性一直都是限制机器学习模型进一步发展的重要因素(沈焕锋和张良培, 2023). 不可否认, 基于相关的方法在地球系统科学研究中已经取得了一系列成功, 但作为科学的一个基本概念, 因果可以拓展传统相关的研究范畴, 在解释、预测、控制和决策等方面发挥重要作用(Zhang等, 2018). 因此, 我们认为在地球系统科学研究中“相关性取代因果”的论断并不合适, 地球系统科学的理论发展依然依赖于对地球物理变量因果关系的深入解读.

简单的因果关系可以根据常识经验判断, 但面对包含众多变量的复杂系统时, 判断因果关系十分困难. 事实上, 识别多变量间的因果关系、量化因果效应本身就是复杂动力系统分析面临的重要挑战(Pearl和Mackenzie, 2018). 随机对照实验是推断因果关系最有效的方法(王东明和陈都鑫, 2022), 但在研究地球系统这样的大规模复杂动力系统时, 介入性实验是行不通的. 模拟实验是当前地球系统因果关系研究的主流方法, 但通常花费巨大、耗时长久且需要大量的专家知识(Stocker, 2014). 近几十年来, 观测(包括地面观测和遥感观测)和地球系统模型输出结果的爆炸式增长, 推动了地球系统科学研究向数据密集型科学发现的范式转换(Guo等, 2017), 数据驱动的因果推理也吸引了越

来越多的关注. 通过建立现象与混淆因素之间的因果共变, 因果推理能确定复杂地球系统中特定组分的独立、实际效果(Li等, 2023). 与经典的统计技术相比, 因果推理可以从数据中区分直接、间接联系和常见的驱动因素, 使得它在地球系统科学中有更好的可行性和适用性(Runge等, 2019a). 例如, 在地球系统科学研究中, 如何识别不同组件的相互作用和相互作用路径? 如何从纷繁复杂的地球系统中分离和量化不同地球物理变量的驱动-响应关系? 如何量化分析子系统/变量对极端事件的影响和贡献? 如何客观评价气候变化的直接和间接影响因素, 稳健预测未来气候变化趋势? 明确地回答这类问题需要破译地球系统不同组分间的因果关系, 分析不同变量间的因果效应, 识别准确的因果路径.

因此, 本文从因果关系的起源和内涵着手, 梳理了因果推理的理论体系和常用方法, 回顾了因果推理在地球系统科学领域的主要应用, 进一步剖析了因果推理在地球系统科学研究中面临的挑战和未来发展方向.

2 因果的源起、内涵与发展

2.1 因果的哲学溯源

在哲学史上, 关于因果的争论已经持续了上千年的历史(图1). “原因”最早的定义来自古希腊哲学家亚里士多德, 他认为原因是用来回答“为什么”的. 在著名的“四因”理论中, 亚里士多德从逻辑上将“形式因”归纳为“第一因”, 认为事物出现的必要条件都应该被称为原因(Sabine和Russell, 1946). 亚里士多德的因果论旨在寻找变化事物背后不变的存在, 对近代西方哲学体系和自然科学体系都产生了深远的影响. 在近代哲学认识论的研究中, 休谟从经验主义立场出发, 深入考察了因果关系, 提出了因果的规则性理论(Hume, 2003). 在方法论上, 休谟不仅提出了“何为原因”而且论证了“如何才能找到原因”, 为因果关系思维和因果推理奠定了基础(Kleinberg, 2015). 康德对因果经验论观点进行了理性批判, 从主体性和目的性的立场重新诠释了因果关系, 提出了因果的“先验解决方案”. 他认为任何事物都必定有其原因, 但原因分析还要诉诸经验. 康德的理论既容纳了对经验主义的理解又肯定了理性主义关于因果先天存在的认知, 是感性经验和

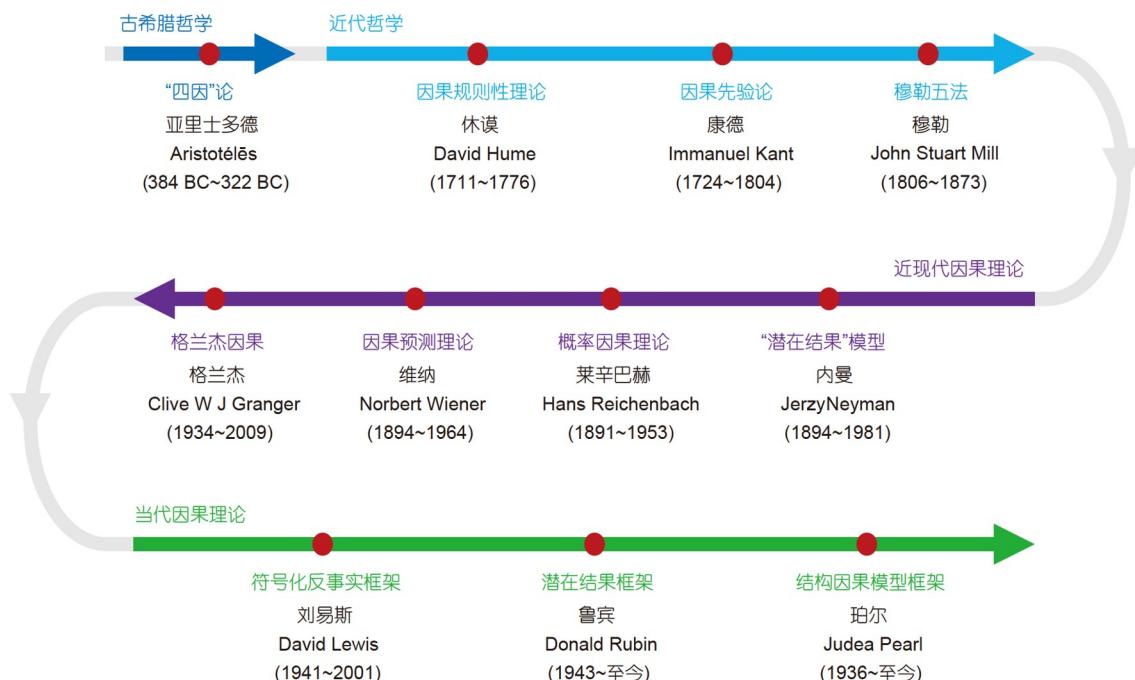


图 1 因果起源概述

理性思维的统一。穆勒赞同因果规则性理论并提出了“穆勒五法”作为因果归纳和推理的基本工具(Mill, 1874)。其中，“求异法”是通过个体的控制和比较来判定因果关系，已经具备了现代因果思想的雏形。简而言之，这一时期对因果的理解主要是围绕着“原因”概念和一般“因果律”构建起来的。

进入20世纪以后，随着实证主义的发展，因果论也从“因果律”转向对概率因果的研究，实现了因果理论的“技术转向”，开始逐步脱离哲学范畴。内曼以农业实验为例，将随机实验与统计推理结合，提出了“潜在结果”模型(Splawa-Neyman等, 1990)。虽然该模型成功地数学化了随机实验中的因果推理，但由于无法解决观察性研究中的随机问题，并未应用在非实验观察研究中。随后，莱辛巴赫提出了概率因果理论(Reichenbach, 1956)，开创了概率因果研究的先河。同时期，控制论之父维纳从预测角度提出了因果预测理论(Wiener和Masani, 1958)。他认为，在时间序列模型中，如果X是Y的原因，那么X的历史信息可以提高Y的预测精度，但这一理论无法在数据分析中取得进一步突破。随后，诺贝尔经济学奖获得者格兰杰利用随机过程的线性自回归模型优化了维纳的因果预测理论，提出了格兰杰因果模型，开启了时序因果推理的新纪元。

(Granger, 1969)。

得益于休谟和康德在哲学上的反事实因果启蒙，刘易斯符号化了反事实框架并提出了完整的反事实因果逻辑链条(Lewis, 1974)，使因果推理的理论研究步入了更高阶段，指明了因果推理研究的前进方向。在反事实理论的指导下，鲁宾认为潜在结果是思考因果关系的有力武器并将其成功用于非实验观察研究(Rubin, 1974)，开创了因果推理中广为认可的潜在结果框架(Potential Outcomes Framework)(Imbens和Rubin, 2015)。随后，图灵奖获得者珀尔综合图模型、结构方程和反事实分析等，提出了一种全新的因果形式化理论，开创了广为认可的结构因果模型框架(Structure Causal Model)(Pearl和Mackenzie, 2018)，极大的推动了因果推理与机器学习耦合的进程(Zhang等, 2018)。虽然潜在结果框架和结构因果模型框架是从两个不同视角发展起来的因果理论，但二者具有内涵同一性和本原一致性。后续将从珀尔建立的因果体系入手，回顾因果关系的三个阶段，深入剖析因果内涵。

2.2 因果关系之梯

珀尔建立的因果分析体系，数学概念清晰，易于算法化，是一套严谨且系统的方法论，被誉为一场“因果

革命”(Pearl, 2000; Schölkopf, 2022). 他通过剖析因果思维形成过程将人类的认知能力划分为三个不同层次, 即观察能力(Seeing)、实践能力(Doing)和想象能力(Imagining), 并进一步在此基础上提出了“因果之梯(ladder of causation)”的概念(图2), 将解构因果关系的方法划分为关联、干预和反事实三个层次, 分别与三种认知能力对应(Pearl和Mackenzie, 2018). 因果关系的第一层是关联, 即通过被动地观察寻找客观规律, 形成规则性因果认识. 在现实中, 关联可以表述为“如果观察到……会怎么样”, 而在统计学中则被称为条件概率($P(Y|X)$). 近几年在地球系统科学研究中广泛使用的机器学习模型, 其底层逻辑就是利用变量间的相互关联进行预测(沈焕锋和张良培, 2023). 因果关系的第二层是干预, 即将被动地观察与主动改变相结合, 形成干预性因果认识, 判断因果关系的存在性和方向性. 例如, 如果对 X 的干预改变了 Y 的分布($P(Y|do(X))$)则称 X 是 Y 的原因. 因果关系的第三层是反事实, 即改变参与形成相关结果的条件项, 估计结果的变化($P(Y_X'|X)$), 是对过去已发生事实的溯因和思考, 也是因果认识的最高境界. 例如, 洪水灾害发生后, 人们一定会反思, 如

果提前开启分蓄洪区或提前建设工程措施, 结果会怎样. 迭代的反事实分析虽然不会改变已经发生的灾害本身, 但能对灾害产生的原因进行梳理, 提出预防灾害的合理建议, 并将之应用到相仿的领域, 最终形成系统的学科知识.

2.3 因果推理框架

在过去的几十年, 在不同学科背景下涌现了一系列的因果推理方法, 但这些方法大多不成体系, 缺乏一般性的理论指导(王东明和陈都鑫, 2022). 随着因果理论的发展, 潜在结果框架(Rubin, 1974; Imbens和Rubin, 2015)和结构因果框架(Pearl, 1995, 2000)逐步成为因果领域两种广为认可的理论体系, 推动了因果理论研究迈入新的发展阶段.

2.3.1 潜在结果模型框架

潜在结果模型框架的核心是比较研究对象在接受干预和不接受干预时的结果差异, 认为这一结果差异就是干预的效果. 然而, 如图3所示, 对任一研究对象, 通常只能观察到一种结果, 其他未观察到的结果即为

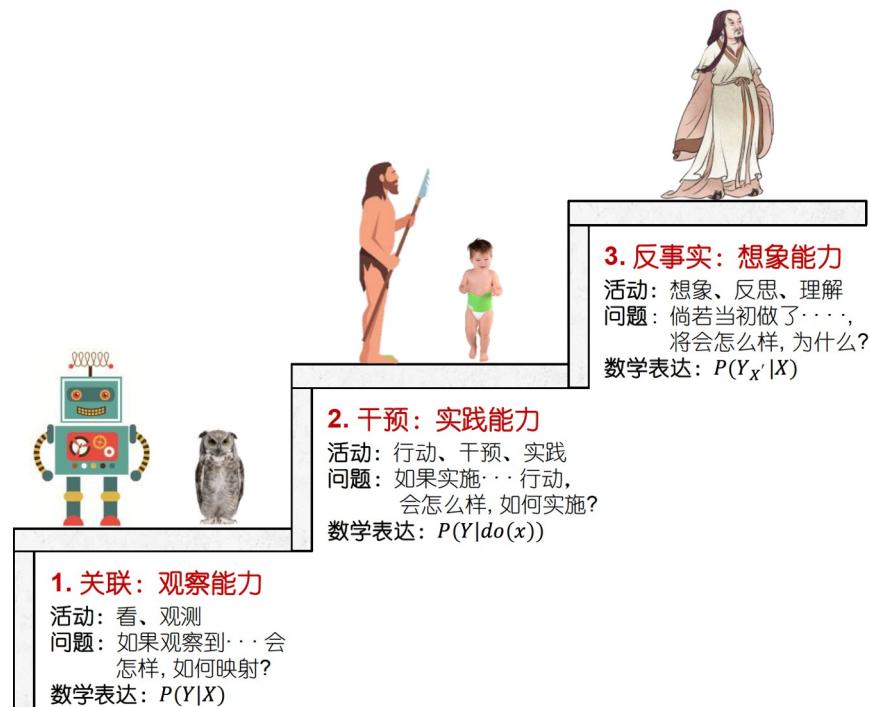


图 2 因果关系之梯

据参考文献Pearl和Mackenzie(2018)修改, 并获得Judea Pearl的授权

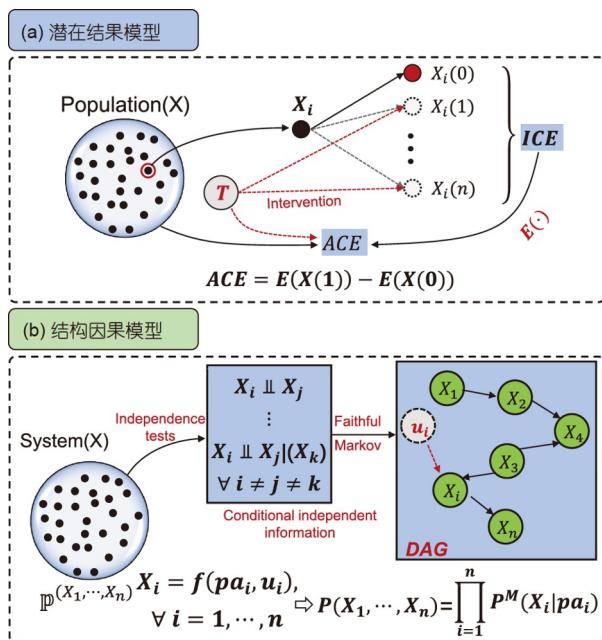


图 3 地球系统的因果推理框架体系

潜在结果。以二元干预为例, 若令 $X_i(1)$ 和 $X_i(0)$ 分别表示研究对象 X_i 在接受干预或未接受干预的结果, 则个体的因果效应(ICE)可定义为: $ICE(i)=X_i(1)-X_i(0)$ 。在总体层面, 平均因果效应(ACE)可以通过群体的平均干预效果获得, 即 $ACE=E(X(1))-E(X(0))$, 其中 $X(1)$ 和 $X(0)$ 分别表示群体潜在干预和非干预结果。潜在结构框架下, 对因果效应的估计是因果推理的重要目标。在实践应用中, 潜在结果模型的研究难点是解决数据缺损问题。由于观察性研究无法通过观察获取研究对象的全部潜在结果, 潜在结果模型试图通过先估计缺损数据(潜在结果), 再利用缺损数据与实际观察结果间的差异推求因果效应。

2.3.2 结构因果模型框架

抛开复杂的理论背景, 结构因果模型框架通常由图模型、结构方程和反事实干预三部分组成。图是一种可视化的数学语言, 由节点和连接节点的边组成(Thulasiraman 和 Swamy, 2011)。在结构因果模型框架内, 因果图通常为有向无环图(DAG), 可以直观地描述节点间的特定关系(Pearl, 2000)。结构方程是因果图的数学孪生, 能够量化节点变量的数据生成机制。如图3所示, 因果图中的任一节点变量 X_i 都可以通过该节点

的父节点集合(pa_i)和潜在外生变量(u_i)通过方程唯一确定, 即 $X_i=f_i(pa_i, u_i)$, $\forall i=1, 2, \dots, n$ (Pearl, 2000)。

在实践中, 结构因果模型的核心是利用条件独立性检验等发现因果图结构, 其中较为成熟的判别标准有前门准则、后门准则等。当然, 根据实际任务需求, 利用专家知识也可以部分获取先验因果图结构, 但无疑重返了“专家系统”的老路。*do*-操作是在结构因果模型框架下实施干预和反事实操作, 进行因果估计的主要方法。不同的是, 干预的*do*-操作是对节点变量实施干预, 而反事实的*do*-操作则同时对节点变量和受其影响的条件(环境变量)实施干预。例如, 在当前环境 Z 中, 对节点变量 X_i 的干预可以表示为: $do(X_i=x)$, 这意味着节点 X_i 的结构方程被修改为 $X_i=x$, 不再受其父节点和外生变量的影响。预测结果 Y 的概率可以表示为 $P(Y|do(X_i=x), Z)$ 。当对节点变量 X_i 实施反事实干预时, 结果 Y 的概率可以表示为: $P(Y|do(X_i=x), Z')$, 其中 Z' 是假设的平行世界, Z' 中所有不受 X_i 影响的环境都与 Z 相同。总的来说, 结构因果模型框架提供了一种从图开始, 挖掘因果结构和数据产生机制, 进而进行因果估计的方法(Pearl 和 Mackenzie, 2018)。

尽管潜在结果模型框架和结构因果模型框架对因果的表述不同, 但二者对因果的理解是一致的, 都可以简述为改变一个变量能够在多大程度上影响另一个变量。结构因果模型表达能力更强, 更擅长描述复杂问题但过于依赖因果图。在处理复杂的现实问题时, 由于问题本身的复杂性, 结构因果模型很难获取完整、准确的因果图, 限制了结构因果模型的应用。潜在结果模型的描述更加简洁且对先验知识要求更低, 因此应用更加广泛, 但潜在结果模型的因果可解释性弱于结构因果模型。

2.4 因果推理方法

2.4.1 格兰杰因果分析

格兰杰因果分析(Granger causality analysis)是首个利用时序观测的规范因果分析方法(Runge 等, 2019a), 其核心思想是: 若时间序列 X 的历史信息有助于提升时间序列 Y 的预测精度, 则称 X 是 Y 的格兰杰原因(Granger, 1969)。传统的格兰杰因果分析利用线性自回归模型解决双变量因果关联, 具有一定的可解释性, 但该方案仅适用于线性、平稳的双变量时间序列

(Seth等, 2015). 为了拓展其适用范围, 众多的研究者对格兰杰因果分析进行了多元化和非线性拓展, 也提供了在非平稳时间序列中应用的解决方案(Moraffah等, 2021). 例如, 条件格兰杰模型为研究高维因果推理奠定了基础(Geweke, 1982; Arize, 1993). 核格兰杰因果分析方法(Liao等, 2009)提升了格兰杰因果分析在非线性系统中的灵活性和适应性. 基于时变自回归的参数估计方法使格兰杰因果分析能用于非平稳系统(Schäck等, 2018).

2.4.2 基于转移熵的因果推理

随着信息论的发展和完善, 利用转移熵(Transfer entropy)等信息度量指标进行因果推理逐渐兴起(Schreiber, 2000). 与格兰杰因果分析相比, 基于信息的因果推理方法直接利用信息流方向进行因果关系推理, 摆脱了传统方法的模型依赖(王东明和陈都鑫, 2022). 然而, 由于该类方法无法有效识别因果路径, 在复杂系统的因果推理中存在较大的局限性(Smirnov, 2013). 此外, 基于信息的因果推理方法需要计算变量的概率密度函数, 随着变量维度的增加, 极易陷入维数诅咒(Bellman, 1966). Runge等(2012)提出了一种基于图模型的维数分解方法, 将转移熵分解为多个有限维转移熵的组合, 一定程度上避免了维数灾难.

虽然基于信息的因果推理方法与格兰杰因果分析的原理和判断依据存在明显差异, 但对于服从高斯分布的变量而言, 二者的结果是等价的(Barnett等, 2009). 例如, 在双变量因果推理中, 基于伪转移熵的因果推理与格兰杰因果分析在多种不同系统(线性、非线性和混沌系统)中的结论十分一致(Silini和Masoller, 2021).

2.4.3 非线性状态空间方法

借助状态空间模型, 现代控制理论可以很好地刻画复杂系统变量间的关系, 进而揭示系统的动力学机制. Takens(1981)提出的状态空间重构理论, 为分析非线性系统的动力学机制提供了数学基础, 也为基于非线性状态空间的因果推理提供了理论依据. 目前, 非线性相互依赖指标和收敛交叉映射是最常用的基于非线性状态空间的因果推理方法. 非线性相互依赖指标利用状态空间的映射关系判断系统的因果关系, 常用的指标有指标 S 和 H (Arnhold等, 1999)、指标 N (Quiroga等, 2000)、指标 M (Andrzejak等, 2003)和指标 L (Chi-

charro和Andrzejak, 2009)等, 其本质都是利用状态空间重构后的距离/秩统计量代表因果方向和因果关系强度. 收敛交叉映射假设相互作用发生在一个潜在的动力系统中, 通过变量的时延嵌入建立因果关系(Sugihara等, 2012; Ye等, 2015). 尽管收敛交叉映射在底层随机过程的交互作用中与格兰杰因果分析十分相似, 但收敛交叉映射采取了动力系统视角对因果关系进行分析, 引起了国内外研究学者的广泛关注, 已经在大气科学、生态科学和水文学研究中广泛采用.

2.4.4 因果发现算法

在结构因果模型框架下, 因果图至关重要, 但通常是未知的. 从观察数据中挖掘因果信息生成因果图的过程又被称为因果发现, 是获取因果结构和因果路径的重要手段. 本质上, 因果发现通过数据反演数据生成机制, 属于逆问题的研究范畴. 为了可解性, 因果发现通常需要一系列的预定义假设, 如马尔可夫条件(Markov condition)和信实假设(Faithfulness assumption)等(Schölkopf等, 2021). 尽管如此, 因果发现依然面临马尔科夫等价类的挑战. 现有的因果发现算法大多是推求预定义假设下的近似解, 进而也形成了各具特色的算法体系.

基于组合优化的算法主要利用数据的条件独立性发掘潜在因果结构. 这类方法通常从一个空图(如PC算法(Hund和Schroeder, 2020))或全连通图(IC算法(Verma和Pearl, 2022))开始, 利用条件独立信息迭代地添加或删除边, 逐步建立因果网络. 条件独立检验是组合优化算法的核心, 可以通过不同类型的测试灵活地进行. 例如, Runge等(2019b)通过耦合PC算法和瞬时条件独立性检验(MCI), 提出了PCMCI算法, 实现了大规模时间序列因果网络重构. 随后, 通过分离存在时延和同期的条件集, 他又提出了PCMCI+算法, 可以在高召回率的前提下有效减少虚假因果(Runge, 2020). 基于组合优化的因果发现算法在气候科学相关领域有很多成功的应用案例.

基于组合优化的因果发现在高维长序列的因果推理中面临严峻的维度挑战, 为了提高求解效率, 基于连续优化的因果发现算法应运而生. 例如NoTears算法将因果结构问题转换为连续优化问题, 在不增加结构假设的基础上, 避免了维数灾难(Zheng等, 2018). DAG-GNN算法在NoTears架构的基础上利用神经网络模型

突破了线性模型的局限性(Yu等, 2019). 基于函数类的因果发现也是结构因果发现方向重要研究方向. LiNGAM方法假设变量间线性关联且误差服从非高斯分布, 依据因果机制的不对称性(Peters等, 2017)和独立成分分析(ICA)(Altman和Krzywinski, 2015)识别因果方向(Shimizu等, 2006). 随后, 大量研究在LiNGAM模型的基础上进行了多方位拓展(Shimizu等, 2011; Hennao和Winther, 2011), 提升了模型的适用范围. 特别地, Hoyer等(2008)提出了加性噪声模型(ANM)方法, 缓解了对噪声非高斯假设的依赖. 更多的因果发现算法请参考Vowels等(2021). 目前, 基于连续优化和函数类的因果发现算法在地球系统科学中的应用十分有限, 但在高维复杂因果网络推演(如生态系统和复杂气候系统)中有很高的潜在价值.

3 因果推理与地球系统科学

把地球作为一个开放的动力系统进行研究时, 由于涉及的变量很多且存在很强的相互依赖, 对地球系统科学的研究方法也提出了更高的要求(周天军等, 2022). 因果理论和推理方法的逐步完善为地球系统科学研究打破传统相关理论的桎梏提供了重要的机遇. 由于地球系统核心变量的多源观测大多以时间序列的形式呈现, 因此利用时间序列观测进行准实验设计一直都是地球系统科学领域因果推理的主流研究方向, 也受到众多地球系统科学研究者的青睐. 值得说明的是时序因果推理本质上植根于两种主流因果推理框架体系, 可以理解为两大理论体系的应用外延.

3.1 时序因果推理

时间序列是指按时间排序的一组随机变量, 反应了变量随时间的变化趋势(Brockwell和Davis, 2009). 在应用层面, 时间序列通常来自真实的动力系统, 系统内部的协同、交互导致系统变量间存在复杂的因果关联. 以地球系统为例, 不同分支系统和变量间存在复杂的相互作用和深度耦合, 共同维系地球系统的动态平衡. 时序因果推理可以发掘时序变量间的驱动-响应关系, 在地球系统物理规律揭示、过程理解、假说验证和理论发展等方面发挥重要作用(Li等, 2023). 虽然时序因果推理植根于两大主要因果理论框架, 但具体的因果推理方法依然相对分散, 大多围绕具体科研任

务进行个性化定制, 忽略了理论方法的普适性. 此外, 高维时间序列的计算复杂度和推理精度、非平稳时间序列的虚假因果、隐变量和因果路径的识别、因果强度的量化、选择偏差等一系列问题也影响了时间序列因果推理的可靠性(曾泽凡等, 2022). 因此, 普适高效的时序因果理论和工具是当前时序因果推理研究的重点发展方向.

3.2 因果推理在地球系统科学中的应用

近年来, 因果推理方法已经成功用于地球系统科学研究的不同领域, 用来解决常见的因果相关问题. 词云图可以提供因果推理在地球系统科学研究中的热点研究领域. 图4展示了2000~2022年间Web of Science核心数据库中以因果推理为主题词筛选的相关研究论文关键词云图. 从图中可以看出, 当前因果推理在地球系统科学研究中的应用主要集中在大气科学、陆地表层科学、生态学及人文地理学领域. 从方法论的角度, 格兰杰因果方法依然是因果推理研究的主流方法, 基于信息熵和非线性状态空间(如交叉收敛隐射等)的多种方法也颇受研究者的青睐, 因果图模型和因果网络发现等结构因果模型框架下的相关研究则刚刚开始崭露头角. 图5归纳了因果推理在地球系统科学分文学科领域的的主要应用, 下文将简要回顾因果推理在这些研究领域的研究进展.

3.2.1 大气科学

作为地球系统的重要组成, 大气系统中的许多物理过程在时间和空间上存在紧密的相互作用. 从因果关系的角度解译这些相互作用, 有助于深入理解地球气候系统的运行机制, 进而改进气候和天气预测模型(Runge等, 2019a). 在大气科学领域, 因果推理常常被用于大气环流的驱动因素分析(Runge等, 2014; Kretschmer等, 2016), 在大气环流的异常检测和归因(MacLeod等, 2021)中也发挥着重要作用(Ebert-Uphoff和Deng, 2012). 气候遥相关是区域天气和气候预测机制的基础, 因果推理在量化遥相关的驱动因素、因果方向、因果路径和强度及滞后时间等方面发挥着重要作用(Runge等, 2015; Nowack等, 2020; Kretschmer等, 2021). 例如, Kretschmer等(2016)通过因果效应网络分析中纬度冬季环流的不同北极驱动因素, 发现巴伦支海和卡拉海秋季的海冰浓度是中纬度地区冬季环流的



图 4 地球系统科学研究中因果推理论相关词云图
图中词的大小表示相应的词频

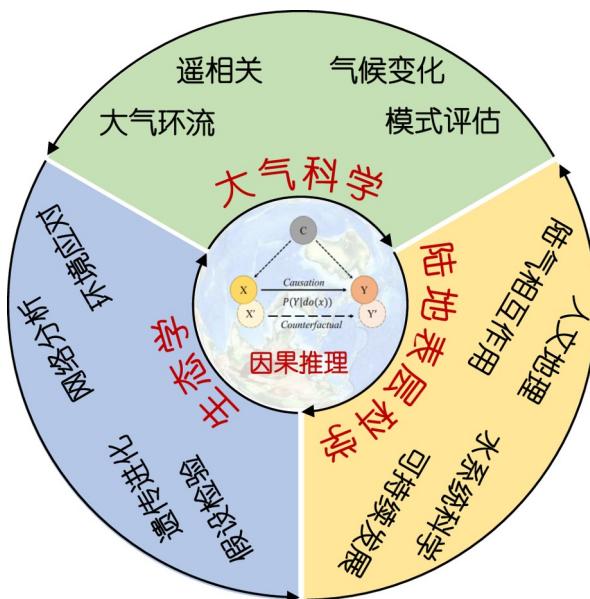


图 5 因果推理论在地球系统科学主要分支领域中的应用

重要驱动因素; Ebert-Uphoff 和 Deng(2012)利用因果图模型推导, 验证了北方冬季大气低频变率四种主要模态之间的因果关系假设。同时期, Di Capua 等(2020)评估了热带对流与中纬度夏季环流在不同季、不同时间尺度上的相互作用, 以及ENSO对这些相互作用的影

响; Kretschmer 等(2021)通过对几种常见遥相关案例的分析指出, 系统的因果推理论方法应该成为遥相关研究的标准实践方案。气候与气候变化一直是大气科学的重点研究领域(黄建平等, 2019)。在全球气候变化背景下, 因果推论还被用于气候变化归因分析(Triacca, 2005; van Nes 等, 2015)和气候模型的因果评价(Nowack 和 Runge, 2018; Nowack 等, 2020; Vázquez-Patiño 等, 2020; Karmouche 等, 2022)。此外, 对大气动力学因果特征的分析可以辅助解译大气环流模式对天气系统的影响, 进而提升对极端天气事件的归因和解释能力(Hannart 等, 2015, 2016; Naveau 等, 2020), 为气候政策和灾害应对提供有价值的参考。

3.2.2 陆地表层科学

陆地表层系统是由气候、地形、地貌、土地、水文等组成的开放、复杂的巨系统, 也是人类最主要的生存环境(李新, 2013; 程国栋和李新, 2015)。陆地表层系统各要素演变规律及其驱动-响应机制是陆地表层系统重点研究内容(陈发虎等, 2019)。目前, 因果推论在陆地表层系统的多个研究领域都有成功的应用。在陆气相互作用领域, 因果推论为识别土壤湿度与降水间的互馈关系提供了新的见解(Salvucci 等, 2002; Li 等, 2020), 并进一步分析了混淆因子对互馈系统的潜在干扰(Tuttle 和 Salvucci, 2017)。在区域气候方面, 因果推论还被用于量化下垫面植被变化对区域气候系统的影响(Jiang 等, 2015; Papagiannopoulou 等, 2017; Budakoti 等, 2021)。此外, Mosedale 等(2006)还在格兰杰因果框架下定量诊断了海面温度对北大西洋涛动的反馈, 为大气环流模型的相关改进提供了重要证据。在水文水资源领域, 2019年提出的“未解决的水文难题”中包含了大量因果相关字眼, 水文过程的因果关系也被誉为水文科学的研究的终极目标(Blöschl 等, 2019)。目前, 因果推论方法已经广泛用于水循环过程的相互作用和反馈机制研究(Wei 等, 2021; You 等, 2021; Bonotto 等, 2022), Goodwell 等(2020)甚至认为以信息论为代表的因果分析开创了水系统科学的新范式。

人地系统是集区域性、综合性与复杂性为一体的巨系统, 一直以来都是人文地理学研究的核心(樊杰, 2019)。人地关系在不同时间尺度的演化规律和反馈机制是理解人地系统的关键(陈发虎等, 2021)。Meyfroidt(2016)认为人地系统的研究可以从结构化、规范化、

明确化的因果推理中受益, 建议加强人地系统因果分析的案例研究, 逆向推动理论发展。Ferraro 等(2019)分析了因果推理在人地系统研究中面临的挑战, 指出高可信度推理结果的对抗集成是应对挑战的重要手段。在人水耦合研究中, 恰当的因果推理方案可以用来解释部分已知的水资源悖论(如地下水的公地悲剧、区域水冲突和虚拟水贸易等), 为应对社会水资源挑战提供参考(Müller 和 Levy, 2019)。同时, 对人水耦合系统因果关系的深入理解也有助于提升对复杂人水系统的评估和预测(Penny 等, 2020)。联合国可持续发展目标(SDGs)为世界可持续发展提供了15年的发展蓝图, 但最近的研究报告表明可持续发展目标的实现面临巨大时间挑战(Fu 等, 2019)。不同发展目标间复杂的相互作用(如协同与博弈)是加剧这一挑战的重要因素(Fu 等, 2020)。越来越多的研究者和从业者认为可以通过相互依存网络对SDGs进行深入解析, 推动实现真正的可持续发展。Ospina-Forero 等(2022)系统地比较了常用的SDG网络分析方法, 指出基于因果推理的图分析方法最适合提供政策建议。以二氧化碳排放为例, 经济增长是影响碳排放的主要因素(Zhang 等, 2014; Al-Mulla 等, 2015)而可再生能源消费能显著降低碳排放(Kayani 等, 2020)。

3.2.3 生态学

随着极端气候事件的加剧, 生态系统服务功能面临严峻的环境挑战, 复杂生态系统的精确预测吸引了越来越多的关注(朴世龙等, 2019)。生态系统内生物和物质的分布、丰度和通量受控于生态系统内和跨系统间的相互作用且对环境变化和管理政策十分敏感(Ad-dicott 等, 2022)。对生态系统相互作用过程的因果解译是提升生态预测的必然途径。长期以来, 随机实验都是生态学中因果研究的主流方法, 基于非实验观测的因果推理也起源于随机实验(Laubach 等, 2021), 用于弥补随机实验的不足(Kimmel 等, 2021)、指导实验方案设计(Williams 和 Brown, 2019)、识别混杂因素影响(Arif 和 MacNeil, 2023), 在生态系统网络(Li 和 Convertino, 2021; Barraquand 等, 2021)和种群相互作用(Pacourneau 等, 2019; Schoolmaster Jr 等, 2020)等多个研究领域取得了初步成功。在环境应对方面, 不少研究者尝试建立物种与气候变量间的因果关联, 如沙丁鱼-凤尾鱼-海面温度问题(Sugihara 等, 2012)、花期的气候诱因

(降水、气温及二者的协同信息)问题(Satake 等, 2021)、种群连通性和基因流动的气候影响研究(Yang 等, 2015)等。在遗传进化的相关研究中, 数据驱动的因果推理为种群遗传差异的溯源提供了新的视角(Dures 等, 2020; Faith 等, 2021)。此外, Dronova 和 Taddeo(2022)认为多源遥感观测与因果推理的搭配对新时期物候学的发展有重要价值。随着多源数据的快速积累, 生态学研究逐步迈入到大数据、大理论、大科学时代(牛书丽等, 2020), 将因果推理纳入生态学常规工具集的时机已经成熟(Larsen 等, 2019)。

3.3 因果推理和大数据结合助力地球系统科学的研究的范式转变

随着信息化和观测分析技术的发展, 科研活动各个环节的数据量呈指数级增长, 科学研究进入“大数据”时代已经成为共识(郭华东等, 2014)。作为科学大数据的重要组成部分, 地球大数据有科学大数据的一般特点, 同时有很强的时空关联和物理关联, 已成为认识地球的新钥匙, 为地球系统科学研究提供了新的发展机遇(Guo 等, 2016)。然而“数据仅仅是数据”, 大数据本身并不能直接解决问题。数据科学是所有类型数据分析的总称, 可以打破传统统计学障碍, 让大数据服务于科学问题(Hernán 等, 2019)。

在地球系统科学的研究中, 依据科学贡献和意义, 数据科学的主要任务可以分为三类, 即描述、预测和反事实预测(或因果推理)(Hernán 等, 2019)。当前, 数据科学在地球系统科学领域的应用大多具有很强的预测性但缺乏因果性。以机器学习/深度学习为例, 在明确预测任务和科学问题后, 用户只需依据学科知识确定输入和输出变量并准备相应的数据, 机器学习可以接管后续的数据分析, 提供映射并量化性能。尽管映射本身可能并不透明, 但机器学习的预测性能通常是值得肯定的。与之不同的是, 因果推理的执行中除了需要明确科学问题、准备相关的数据外还需要对所研究系统的因果结构有必要的科学认知。辅助决策是数据科学的一个重要目标。通常认为, 成功的预测是改善决策能力的基础, 但这一观点是值得怀疑的。例如, 预测性算法可以利用天气信息进行短期洪水预报, 但难以给出降低洪水风险的方案。预测算法也难以处理“如果”问题, 即难以给出不同决策提案的风险-收益情况。在大数据背景下, 因果推理能够从传统的模型范式中

汲取专家知识, 提供反事实预测结果, 在辅助决策中占据天然优势。因此, 复杂地球系统的决策分析十分依赖具有因果知识的数据分析方法。

综上所述, 数据科学有望为大数据背景下地球系统科学研究发展提供关键技术手段, 推动地球系统科学研究从传统模型范式向数据驱动范式的转变。作为最重要的大数据分析方法之一, 因果推断是联系模型范式和数据驱动范式的纽带, 在数据科学任务中持续发挥基础和引领作用, 助力地球系统科学的研究范式转换, 实现模型-数据双驱动的研究范式。

4 面临的挑战与发展方向

因果推理作为一种高阶大数据分析方法, 在地球系统科学假说验证、过程理解、规律揭示和知识发现中发挥着不可替代的作用, 但在利用非实验地球大数据进行因果推断中挑战与机遇共存。

4.1 面临的挑战

4.1.1 因果机制检验

因果推理的最终目标是利用干预后的潜在/反事实结果获取因果效应(Rosenbaum和Rubin, 1983)。然而, 由于不同因果推理框架对因果关系的定义不同, 因果机制的检验方法也存在明显差异。在潜在结果模型框架下, 假设相同的干预会产生相同的潜在结果且潜在结果与观测结果服从相同的分布(Rubin, 1980)。因此, 可以通过观测样本与潜在结果分布对因果机制进行检验。结构因果框架利用因果图模拟反事实结果的推理过程。因此, 结构因果框架仅仅假设因果推理过程是正确的, 对反事实结果的分布不作任何额外假设(Imbens和Rubin, 2015; Peters等, 2017)。尽管部分研究者依然利用反事实结果与实际观测结果间的分布偏移进行因果检验(Ness等, 2019; Pawłowski等, 2020), 但分布偏移更小理论上并不能证明结构因果框架下的因果模型更优。事实上, 结构因果框架下的因果机制检验依然依赖算法设计者对目标系统的先验认知, 从而对研究结果进行合理性解释。总的来说, 在不同的因果推理框架下, 因果机制的检验或过于依赖假设或无法从理论上检验。因此, 对因果机制不明的复杂系统, 因果机制的发现和检验是当前因果推理领域的根本挑战也是最主要的难点之一。

4.1.2 因果推理实验设计

假设数据生成机制是因果推理的必要条件, 这些先验假设可能在数学上是合理且必要的(Kretschmer等, 2021), 但在地球系统科学的应用推广中仍需谨慎。地球物理变量和目标区域的选择是地球系统因果推理实验设计中面临的现实挑战。以气候系统研究为例, 为了完成特定的科学任务, 需要从网格化时空数据集中提取相应的时间序列, 但气候变量和目标区域的选择需要可靠的专家知识和额外的合理假设。此外, 不同变量间相互作用的时间尺度可能存在巨大差异, 选择合适的时间尺度对获取稳健的因果推理结果至关重要(Fernández-Loria和Provost, 2022)。空间异质性也是地球系统因果推断面临的重要挑战之一。例如, 在下垫面干湿状态不同的地块, 土壤湿度与降水间的互馈机制可能存在明显的差异(Taylor等, 2012; Guillod等, 2015)。最后, 变量及噪声的分布也是地球系统因果推理研究中需要重点关注的问题。例如, 降水的概率分布可能是非高斯的且带有表征大雨和极端降水的曳尾现象, 需要谨慎评估、选择合适的因果推理方法。当然, 部分因果推断方法还依赖于变量的平稳性假设, 在地球系统因果推理中需要消除变量的季节性周期和潜在趋势。

4.1.3 隐变量的识别

作为一个开放的巨系统, 地球系统涉及的因素和变量很多且这些状态变量杂糅在复杂的时变动力系统中, 如何处理多变量的动态反馈、识别循环过程是因果推理在地球系统科学研究中面临的重要挑战。在地球系统的因果推理中, 隐变量通常指难以观测、隐藏/未知变量或存在强不确定性的变量。由于对地球系统状态的不完全观测(包括时间和空间), 隐变量必然存在, 进而催生混淆因素干扰(Peng和Susan, 2022)。如何获取精细化、系统的地球系统同步观测是几乎所有因果推理研究面临的共同挑战。除混淆因素外, 在地球系统变量的观测中, 选择偏差几乎不可避免, 如受云层或运行轨道限制, 卫星观测只能在特定的时间采样等, 进一步降低了推理结果的鲁棒性(Shen等, 2020)。因此, 发现隐变量局部结构并给出度量方法也是当前地球系统因果推理面临的重要挑战。随着大数据时代的到来, 利用大数据来全方位地刻画变量间的结构信息(因果发现)以及通过检验因果图结构中的虚假因果关系反

证出难以观察到的隐变量结构, 将为这方面研究带来新的契机(Vowels 等, 2021).

4.1.4 验证数据的匮乏

因果推理算法的开发、评估和比较都需要具有已知因果关系的基准数据集进行验证。在理想情况下, 基准验证数据来自因果关系明确的真实数据或随机实验的先验知识, 但目前可用的公开基准数据集很少, 已经成为公认限制因果推理算法发展的核心瓶颈(Runge 等, 2019a)。出现这种情况的主要原因是在很多场景下, 隐藏在数据背后的因果机制本身就是复杂且未知的。发展科学的验证方法和持续积累因果机制明确的验证数据集是解决因果推理算法评价的有效手段。利用简化的地球物理模型生成因果机制明确的合成数据, 是一种重要的替代方案(Ombadi 等, 2020), 但这类合成数据集在地球系统科学的研究中依然很难获取。在这种背景下, 如何挑选合适的数据集和假设方案, 进而定制或筛选恰当的因果推理方案以应对任务需求是地球系统因果推理面临的严峻挑战。

4.2 发展方向

4.2.1 因果推理与地球物理模型的耦合

观测和模型是地球系统研究的两种重要手段(李新等, 2020)。即便在“现实世界简单化”前提下, 模型的开发依然需要海量的学科知识。数据基础上的规律性认识、实验认知、现有知识的适度外延和移植是获取学科知识的主要方式, 与人类三种认知能力正好对应, 也符合因果之梯描述的三个层次。因此, 地球系统模型的构建本身就难以脱离潜在的数据分析和因果推理。随着因果理论和推理方法的进步, 对地球系统的科学认识也在逐步加深, 对识别现有地球物理模型的缺陷和模型改进有巨大的推动作用。基于大数据的因果推理还可以进一步指导模型中部分复杂的参数化方案设计, 提升模型精度(Runge 等, 2019a)。同时, 因果推理可以获取地球系统变量间的直接关联和间接关联, 指导模型架构。此外, 地球系统本身十分复杂, 现有的地球系统模型大多是对其中部分物理过程的简化, 依然存在很多物理机制尚不清楚或尚未完全认知的物理过程。通过准实验方案, 因果推理可以利用多源观测增加对未知物理过程的理解, 推动物理模型的新发展。从这个角度, 因果推理有助于催生更加完善的地球系统模

型(图6)。

模型是现有地球系统学科知识的集大成者, 在地球系统的过程理解中起着基础性作用。物理模型的构建部分依赖已知过程的微分方程, 部分依赖代表未知过程的半经验关系。通过对观测数据的拟合, 物理模型往往能够准确地模拟“现实”地球甚至完成对“未来”地球的预测(Li 等, 2022)。从这个角度, 利用地球系统模型可输出或结合观测数据生成大规模合成数据, 为因果推理提供充足的“观测数据”, 进而推动因果理论的完善。此外, 无论是从地球物理模型中汲取的理论知识还是建模过程的物理约束, 都可以为因果推理提供先验知识, 规范因果推理方法, 为因果推断结果提供科学解释(图6)。此外, 理论完善、结构合理的地球系统模型还可以辅助因果推理进行反事实模拟, 为因果推理提供部分干预情景下的潜在结果(Kretschmer 等, 2021), 完善潜在结果框架下的因果效应估算, 提升推理结果的可解释性。因此, 地球物理模型能够推动因果理论的发展、完善因果推理框架、增加因果推理结果的可解释性。

基于此, 因果推理与地球物理模型并不是简单的耦合, 而是双向奔赴, 相互促进。因果推理与物理模型的协同发展有助于更好地理解地球系统, 也是推动地球系统科学的重要发展方向。

4.2.2 因果推理与机器学习的结合

长期以来, 因果推理和机器学习各自发展壮大, 随着逐渐步入瓶颈期, 二者的交叉互益正快速成为人工智能领域新的增长点和突破口(Schölkopf 等, 2021)。尽管机器学习在很多研究领域都已经取得了重大成功, 但在实践应用中依然面临着重要挑战。首先, 机器学习模型缺乏可解释性, 即无法解释机器学习模型做出判断的逻辑和原因, 只能无条件地肯定或否定, 难以辩证地吸收采纳。其次, 目前大多数机器学习都依赖于数据的独立同分布假设, 即训练数据集和测试数据集的数据分布是相似的, 无法保障稳定地获取预测结果(Peng 和 Susan, 2022)。同时, 独立同分布假设也进一步影响了机器学习模型的知识迁移能力, 限制了机器模型的跨系统/数据分布应用(沈焕锋和张良培, 2023)。通过探究变量间的因果关系, 能够帮助机器学习获得泛化分布外的稳健预测能力(图6)。如何弥合因果推理和机器学习之间的鸿沟, 实现二者的有机结合受到了

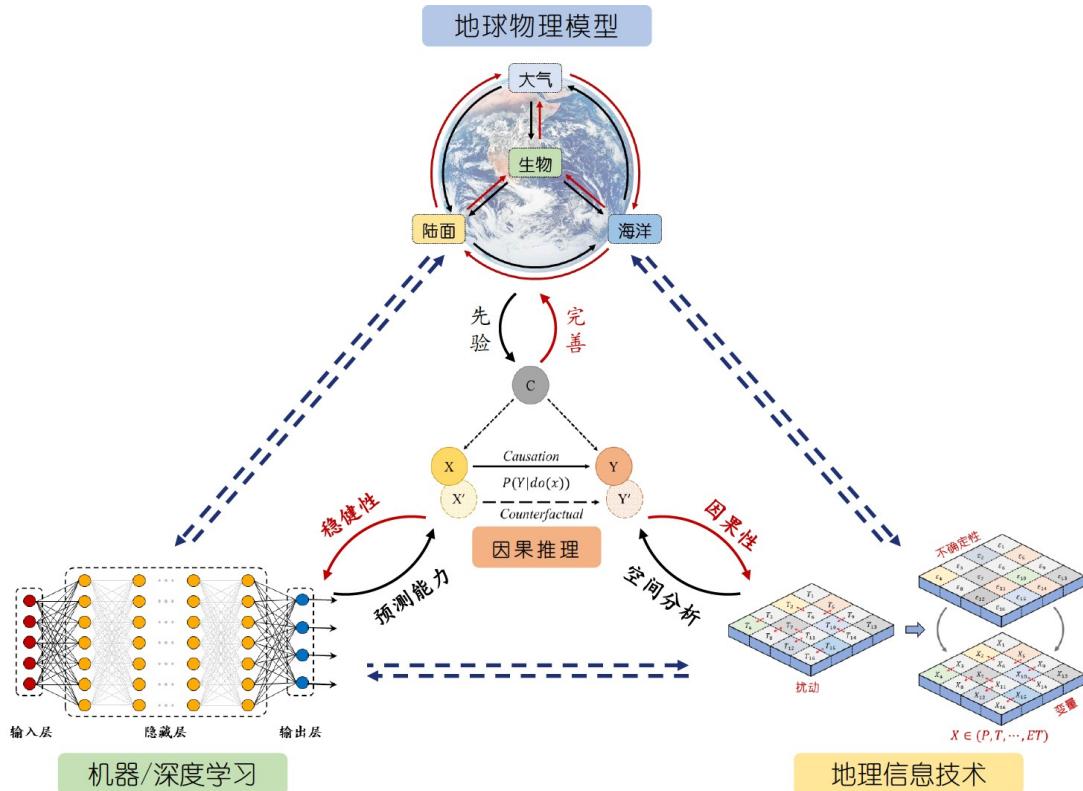


图 6 因果推理在地球系统科学中的发展方向

国内外学者的广泛关注(Schölkopf等, 2021). Peng和Susan(2022)利用因果性特征训练神经网络模型, 提升了模型在不同环境下稳健性. 通过添加一个因果层, Yang等(2021)提出一个新的变分自编码器框架(CausalVAE), 在一定程度上再现了真实系统, 也证明了该模型可以通过 do 操作生成反事实结果. 因果性学习是目前将因果推理与机器学习结合最紧密的前沿研究领域之一, 可以应对机器学习的独立同分布的假设, 提高机器学习的泛化能力和稳健性. 依据能否先验获取因果信息, 因果性学习可以分为两大类: 基于先验因果信息和基于未知因果信息(Yao等, 2021). 基于先验因果信息的因果性学习方法通常假定目标系统的因果结构已知, 但可能存在潜在的隐变量; 基于未知因果信息的因果性学习方法通常需要额外地学习因果信息, 如因果结构学习(Kalisch和Bühlmann, 2014)、因果表征学习(Schölkopf, 2022)等. 尽管已经有了一些探索性研究(Peters等, 2017; Schölkopf等, 2021; Schölkopf, 2022; Mouli和Ribeiro, 2022), 因果推理与机器学习的

互助共赢还处于初级阶段, 后续研究依然任重道远.

4.2.3 空间因果推理

随着因果理论的发展和推理手段的完善, 因果推断在地球系统不同分支学科的应用中大放异彩, 但大多数的因果推理应用都依赖时间非对称假设, 关于空间因果推理的研究依然存在不足(Gao等, 2022). 究其原因, 空间过程的特殊性(如空间依赖性、空间异质性等)会导致伪因果的出现, 混淆对推理结果的解释(Akbari等, 2021). 此外, “地理学第一定律”指出所有事物都与其他事物相关且距离越近关联性越强, 这意味着在现实世界中没有完全空间独立事件. 目前的空间因果推理研究大多尝试将非空间过程的因果推理方法直接移植到空间过程(Gao等, 2022), 缺乏对空间过程的针对性处理, 难以满足因果独立性假设. 此外, 由于空间溢出效应, 未接受干预区域会间接的受到相邻接受干预区域的间接影响(Reich等, 2021), 为了准确推断因果关系, 必须对这些间接影响进行评估并在可能的

情况下进行过滤。同时, 空间溢出效应同样打破了因果推理研究中的个体独立性假设, 为后续的统计估计带来了一系列棘手问题。因果推理算法与空间统计模型的深度耦合可能是解决这些棘手问题的有效途径(图 6)。因此, 为了从空间过程的因果推理中受益, 针对性的空间因果推理方法和框架体系是未来因果推理的重要发展方向。

5 结语

因果科学起源于哲学, 受益于现代统计学和信息科学, 已经形成了完整的方法论体系。通过建立现象与混淆因素间的因果共变, 因果推理能够挖掘大数据背后隐藏的因果信息, 为深入理解地球系统提供了新的视角, 在地球系统规律揭示、过程理解、假说检验和模型改进等多个研究方向展现出蓬勃的生命力。同时, 因果推理可以从数据中区分直接、间接联系和常见的驱动因素, 这使得它能够打破传统相关性研究的桎梏, 在解释、预测、控制和决策等方面发挥重要作用。尽管已经在地球系统科学取得了重大成功, 但当前地球系统科学的因果推理研究大多关注气候系统等分支领域, 缺乏对地球系统框架结构及统筹性关键过程的挖掘, 阻碍了对地球系统的整体认知。同时, 不同研究者对因果推理方法的个性化定制也会影响对推理结果的解读, 不同推理结果的产生可能会动摇对地球系统物理过程的认知基础。因此, 结构化、规范化、明确化的因果推理顶层方案设计和通用工具集是统筹地球系统科学认知基础的。此外, 系统梳理地球系统科学领域中常用的因果推理方法, 规范因果推理假设及相应的检验方法, 制定因果推理全链条术语(如因果效应、因果机制、驱动因素、因果路径等)的定义和含义也是地球系统因果分析亟待解决的迫切任务。进入地球大数据时代, 因果推理在地球系统的应用, 机遇与挑战并存。因果推理与物理模型和机器学习的结合及空间因果推理未来可期, 但也面临实验方案设计、隐变量识别和可靠验证数据匮乏的挑战。

参考文献

- 曾泽凡, 陈思雅, 龙洗, 金光. 2022. 基于观测数据的时间序列因果推断综述. 大数据, doi: 10.11959/j.issn.2096-0271.2022059
- 陈发虎, 傅伯杰, 夏军, 吴铎, 吴绍洪, 张镱锂, 孙航, 刘禹, 方小敏, 秦伯强, 李新, 张廷军, 刘宝元, 董治宝, 侯书贵, 田立德, 徐柏青, 董广辉, 郑景云, 杨威, 王鑫, 李再军, 王飞, 胡振波, 王杰, 刘建宝, 陈建徽, 黄伟, 侯居峙, 蔡秋芳, 隆浩, 姜明, 胡亚鲜, 冯晓明, 莫兴国, 杨晓燕, 张东菊, 王秀红, 尹云鹤, 刘晓晨. 2019. 近70年来中国自然地理与生存环境基础研究的重要进展与展望. 中国科学: 地球科学, 49: 1659–1696
- 陈发虎, 李新, 吴绍洪, 樊杰, 熊巨华, 张国友. 2021. 中国地理科学学科体系浅析. 地理学报, 76: 2069–2073
- 程国栋, 李新. 2015. 流域科学及其集成研究方法. 中国科学: 地球科学, 45: 811–819
- 樊杰. 2019. 中国人文地理学70年创新发展与学术特色. 中国科学: 地球科学, 49: 1697–1719
- 郭华东, 王力哲, 陈方, 梁栋. 2014. 科学大数据与数字地球. 科学通报, 59: 1047–1054
- 黄建平, 陈文, 温之平, 张广俊, 李肇新, 左志燕, 赵庆云. 2019. 新中国成立70年以来的中国大气科学研究: 气候与气候变化篇. 中国科学: 地球科学, 49: 1607–1640
- 李新, 刘丰, 方苗. 2020. 模型与观测的和弦地球系统科学中的数据同化. 中国科学: 地球科学, 50: 1185–1194
- 李新. 2013. 陆地表层系统模拟和观测的不确定性及其控制. 中国科学: 地球科学, 43: 1735–1742
- 牛书丽, 王松, 汪金松, 夏建阳, 于贵瑞. 2020. 大数据时代的整合生态学研究——从观测到预测. 中国科学: 地球科学, 50: 1323–1338
- 朴世龙, 张新平, 陈安平, 刘强, 连旭, 王旭辉, 彭书时, 吴秀臣. 2019. 极端气候事件对陆地生态系统碳循环的影响. 中国科学: 地球科学, 49: 1321–1334
- 沈焕锋, 张良培. 2023. 地球表层特征参量反演与模拟的机理学习耦合范式. 中国科学: 地球科学, 53: 546–560
- 王东明, 陈都鑫. 2022. 因果推断: 起源和发展. 控制工程, 29: 464–473
- 徐道一. 1986. 地学研究中的因果关系与相关关系. 矿物岩石地球化学通报, 5: 66–66
- 周天军, 张文霞, 陈德亮, 张学斌, 李超, 左萌, 陈晓龙. 2022. 2021年诺贝尔物理学奖解读: 从温室效应到地球系统科学. 中国科学: 地球科学, 52: 579–594
- Addicott E T, Fenichel E P, Bradford M A, Pinsky M L, Wood S A. 2022. Toward an improved understanding of causation in the ecological sciences. *Front Ecol Environ*, 20: 474–480
- Akbari K, Winter S, Tomko M. 2021. Spatial causality: A systematic review on spatial causal inference. *Geograph Anal*, 55: 56–89
- Al-Mulali U, Ozturk I, Lean H H. 2015. The influence of economic growth, urbanization, trade openness, financial development, and renewable energy on pollution in Europe. *Nat Hazards*, 79: 621–644

- Altman N, Krzywinski M. 2015. Association, correlation and causation. *Nat Methods*, 12: 899–900
- Anderson C. 2008. The end of theory: The data deluge makes the scientific method obsolete. *Wired Magazine*, 16: 07
- Andrzejak R G, Kraskov A, Stögbauer H, Mormann F, Kreuz T. 2003. Bivariate surrogate techniques: Necessity, strengths, and caveats. *Phys Rev E*, 68: 066202
- Arif S, MacNeil M A. 2023. Applying the structural causal model framework for observational causal inference in ecology. *Ecol Monogr*, 93: e1554
- Arize A C. 1993. Determinants of income velocity in the United Kingdom: Multivariate granger causality. *Am Economist*, 37: 40–45
- Arnhold J, Grassberger P, Lehnertz K, Elger C E. 1999. A robust method for detecting interdependences: Application to intracranially recorded EEG. *Phys D-Nonlinear Phenomena*, 134: 419–430
- Aslam A. 2015. Research ideas: Correlation does not imply causation. *Br Dent J*, 219: 49
- Barnett L, Barrett A B, Seth A K. 2009. Granger causality and transfer entropy are equivalent for Gaussian variables. *Phys Rev Lett*, 103: 238701
- Barraquand F, Picoche C, Detto M, Hartig F. 2021. Inferring species interactions using Granger causality and convergent cross mapping. *Theor Ecol*, 14: 87–105
- Bellman R. 1966. Dynamic programming. *Science*, 153: 34–37
- Blöschl G, Bierkens M F P, Chambel A, Cudennec C, Destouni G, Fiori A, Kirchner J W, McDonnell J J, Savenije H H G, Sivapalan M, and other 195 coauthors. 2019. Twenty-three unsolved problems in hydrology (UPH)—A community perspective. *Hydrological Sci J*, 64: 1141–1158
- Bonotto G, Peterson T J, Fowler K, Western A W. 2022. Identifying causal interactions between groundwater and streamflow using convergent cross-mapping. *Water Resources Res*, 58, doi: 10.1029/2021WR030231
- Brockwell P J, Davis R A. 2009. Time Series: Theory and Methods. New York: Springer. 596
- Budakoti S, Chauhan T, Murtugudde R, Karmakar S, Ghosh S. 2021. Feedback from vegetation to interannual variations of Indian summer monsoon rainfall. *Water Resources Res*, 57, doi: 10.1029/2020WR028750
- Calude C S, Longo G. 2017. The deluge of spurious correlations in big data. *Found Sci*, 22: 595–612
- Chicharro D, Andrzejak R G. 2009. Reliable detection of directional couplings using rank statistics. *Phys Rev E*, 80: 026217
- Di Capua G, Runge J, Donner R V, van den Hurk B, Turner A G, Vellore R, Krishnan R, Coumou D. 2020. Dominant patterns of interaction between the tropics and mid-latitudes in boreal summer: Causal relationships and the role of timescales. *Weather Clim Dynam*, 1: 519–539
- Dronova I, Taddeo S. 2022. Remote sensing of phenology: Towards the comprehensive indicators of plant community dynamics from species to regional scales. *J Ecol*, 110: 1460–1484
- Dures S G, Carbone C, Savolainen V, Maude G, Gottelli D. 2020. Ecology rather than people restrict gene flow in Okavango-Kalahari lions. *Anim Conserv*, 23: 502–515
- Ebert-Uphoff I, Deng Y. 2012. Causal discovery for climate research using graphical models. *J Clim*, 25: 5648–5665
- Faith J T, Du A, Behrensmeyer A K, Davies B, Patterson D B, Rowan J, Wood B. 2021. Rethinking the ecological drivers of hominin evolution. *Trends Ecol Evol*, 36: 797–807
- Fernández-Loría C, Provost F. 2022. Causal decision making and causal effect estimation are not the same... and why it matters. *INFORMS J Data Sci*, 1: 4–16
- Ferraro P J, Sanchirico J N, Smith M D. 2019. Causal inference in coupled human and natural systems. *Proc Natl Acad Sci USA*, 116: 5311–5318
- Fu B, Wang S, Zhang J, Hou Z, Li J. 2019. Unravelling the complexity in achieving the 17 sustainable-development goals. *Natl Sci Rev*, 6: 386–388
- Fu B, Zhang J, Wang S, Zhao W. 2020. Classification-coordination-collaboration: A systems approach for advancing sustainable development goals. *Natl Sci Rev*, 7: 838–840
- Gao B, Li M, Wang J, Chen Z. 2022. Temporally or spatially? Causation inference in earth system sciences. *Sci Bull*, 67: 232–235
- Geweke J. 1982. Measurement of linear dependence and feedback between multiple time series. *J Am Statist Assoc*, 77: 304–313
- Goodwell A E, Jiang P, Ruddell B L, Kumar P. 2020. Debates—Does information theory provide a new paradigm for Earth Science? *Water Resour Res*, 56, doi: 10.1029/2019WR026398
- Granger C W J. 1969. Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37: 424–438
- Guillod B P, Orlowsky B, Miralles D G, Teuling A J, Seneviratne S I. 2015. Reconciling spatial and temporal soil moisture effects on afternoon rainfall. *Nat Commun*, 6: 6443
- Guo H, Liu Z, Jiang H, Wang C, Liu J, Liang D. 2017. Big Earth data: A new challenge and opportunity for Digital Earth's development. *Int J Digital Earth*, 10: 1–12
- Guo H, Wang L, Liang D. 2016. Big Earth data from space: A new engine for Earth science. *Sci Bull*, 61: 505–513
- Hannart A, Pearl J, Otto F E L, Naveau P, Ghil M. 2016. Causal counterfactual theory for the attribution of weather and climate-

- related events. *Bull Am Meteorol Soc*, 97: 99–110
- Hannart A, Vera C, Cerne B, Otto F E L. 2015. Causal influence of anthropogenic forcings on the Argentinian heat wave of December 2013. *Bull Am Meteorol Soc*, 96: S41–S45
- Henao R, Winther O. 2011. Sparse linear identifiable multivariate modeling. *J Mach Learn Res*, 12: 863–905
- Hernán M A, Hsu J, Healy B. 2019. A second chance to get causal inference right: A classification of data science tasks. *Chance*, 32: 42–49
- Hoyer P, Janzing D, Mooij J M, Peters J, Schölkopf B. 2008. Nonlinear causal discovery with additive noise models. *Adv Neural Inform Process Syst*, 21, doi: 10.5555/2981780.2981866
- Hume D. 2003. *A Treatise of Human Nature*. New York: Courier Corporation. 728
- Hund L, Schroeder B. 2020. A causal perspective on reliability assessment. *Reliability Eng Syst Saf*, 195: 106678
- Imbens G W, Rubin D B. 2015. *Causal Inference in Statistics, Social, and Biomedical Sciences*. Cambridge: Cambridge University Press. 625
- Jiang B, Liang S, Yuan W. 2015. Observational evidence for impacts of vegetation change on local surface climate over northern China using the Granger causality test. *J Geophys Res-Biogeosci*, 120: 1–12
- Kalisch M, Bühlmann P. 2014. Causal structure learning and inference: A selective review. *Qual Tech Quantitative Manage*, 11: 3–21
- Karmouche S, Galytska E, Runge J, Meehl G A, Phillips A S, Weigel K, Eyring V. 2022. Regime-oriented causal model evaluation of Atlantic-Pacific teleconnections in CMIP6. *EGUphere*, doi: 10.5194/egusphere-2022-1013
- Kayani G M, Ashfaq S, Siddique A. 2020. Assessment of financial development on environmental effect: Implications for sustainable development. *J Clean Prod*, 261: 120984
- Kimmel K, Dee L E, Avolio M L, Ferraro P J. 2021. Causal assumptions and causal inference in ecological experiments. *Trends Ecol Evol*, 36: 1141–1152
- Kleinberg S. 2015. Why: A guide to finding and using causes. O'Reilly Media. 284
- Kretschmer M, Adams S V, Arribas A, Prudden R, Robinson N, Saggioro E, Shepherd T G. 2021. Quantifying causal pathways of teleconnections. *Bull Am Meteorol Soc*, 102: E2247–E2263
- Kretschmer M, Coumou D, Donges J F, Runge J. 2016. Using causal effect networks to analyze different arctic drivers of midlatitude winter circulation. *J Clim*, 29: 4069–4081
- Larsen A E, Meng K, Kendall B E. 2019. Causal analysis in control-impact ecological studies with observational data. *Methods Ecol Evol*, 10: 924–934
- Laubach Z M, Murray E J, Hoke K L, Safran R J, Perng W. 2021. A biologist's guide to model selection and causal inference. *Proc R Soc B*, 288: 20202815
- Lewis D. 1974. Causation. *J Philos*, 70: 556–567
- Li J, Convertino M. 2021. Inferring ecosystem networks as information flows. *Sci Rep*, 11: 7094
- Li L, Shangguan W, Deng Y, Mao J, Pan J J, Wei N, Yuan H, Zhang S, Zhang Y, Dai Y. 2020. A causal inference model based on random forests to identify the effect of soil moisture on precipitation. *J Hydrometeorol*, 21: 1115–1131
- Li X, Cheng G, Fu B, Xia J, Zhang L, Yang D, Zheng C, Liu S, Li X, Song C, Kang S, Li X, Che T, Zheng Y, Zhou Y, Wang H, Ran Y. 2022. Linking critical zone with watershed science: The example of the Heihe River basin. *Earth's Future*, 10: E2022EF002966
- Li X, Feng M, Ran Y, Su Y, Liu F, Huang C, Shen H, Xiao Q, Su J, Yuan S, Guo H. 2023. Big data in Earth system science and progress towards a digital twin. *Nat Rev Earth Environ*, 4: 319–332
- Liao W, Marinazzo D, Pan Z, Gong Q, Chen H. 2009. Kernel Granger causality mapping effective connectivity on fMRI data. *IEEE Trans Med Imag*, 28: 1825–1835
- MacLeod D, Graham R, O'Reilly C, Otieno G, Todd M. 2021. Causal pathways linking different flavours of ENSO with the Greater Horn of Africa short rains. *Atmos Sci Lett*, 22, doi: 10.1002/asl.1015
- Meyfroidt P. 2016. Approaches and terminology for causal analysis in land systems science. *J Land Use Sci*, 11: 501–522
- Mill J S. 1874. *A System of Logic, Ratiocinative and Inductive: Being a Connected View of the Principles of Evidence and the Methods of Scientific Investigation*. New York: Harper and Brothers. 659
- Moraffah R, Sheth P, Karami M, Bhattacharya A, Wang Q, Tahir A, Raglin A, Liu H. 2021. Causal inference for time series analysis: Problems, methods and evaluation. *Knowl Inf Syst*, 63: 3041–3085
- Mosedale T J, Stephenson D B, Collins M, Mills T C. 2006. Granger causality of coupled climate processes: Ocean feedback on the North Atlantic Oscillation. *J Clim*, 19: 1182–1194
- Mouli S C, Ribeiro B. 2022. Asymmetry learning for counterfactually-invariant classification in ood tasks. International Conference on Learning Representations
- Müller M F, Levy M C. 2019. Complementary vantage points: Integrating hydrology and economics for sociohydrologic knowledge generation. *Water Resour Res*, 55: 2549–2571
- Naveau P, Hannart A, Ribes A. 2020. Statistical methods for extreme event attribution in climate science. *Annu Rev Stat Appl*, 7: 89–110
- Nearing G S, Ruddell B L, Bennett A R, Prieto C, Gupta H V. 2020. Does information theory provide a new paradigm for Earth science? Hypothesis testing. *Water Resour Res*, 56, doi: 10.1029/2019WR024918

- Ness R, Paneri K, Vitek O. 2019. Integrating Markov processes with structural causal modeling enables counterfactual inference in complex systems. Vancouver: Advances in Neural Information Processing Systems, 32, doi: 10.48550/arXiv.1911.02175
- Nowack P J, Runge J. 2018. Large-scale causal network discovery in CMIP5 models: Robustness and intercomparison. Washington: AGU Fall Meeting Abstracts
- Nowack P, Runge J, Eyring V, Haigh J D. 2020. Causal networks for climate model evaluation and constrained projections. *Nat Commun*, 11: 1415
- Ombadi M, Nguyen P, Sorooshian S, Hsu K L. 2020. Evaluation of methods for causal discovery in hydrometeorological systems. *Water Resour Res*, 56: 22
- Ospina-Forero L, Castañeda G, Guerrero O A. 2022. Estimating networks of sustainable development goals. *Inf Manage*, 59: 103342
- Pacourea N, Authier M, Delord K, Barbraud C. 2019. Population response of an apex Antarctic consumer to its prey and climate fluctuations. *Oecologia*, 189: 279–291
- Papagiannopoulou C, Miralles D G, Decubber S, Demuzere M, Verhoest N E C, Dorigo W A, Waegeman W. 2017. A non-linear Granger-causality framework to investigate climate–vegetation dynamics. *Geosci Model Dev*, 10: 1945–1960
- Pawlowski N, Coelho de C D, Glocker B. 2020. Deep structural causal models for tractable counterfactual inference. *Adv Neural Inform Process Syst*, 33, doi: 10.48550/arXiv.2006.06485
- Pearl J, Mackenzie D. 2018. The book of why: The new science of cause and effect. *Science*, 361: 855–855
- Pearl J. 1995. Causal diagrams for empirical research. *Biometrika*, 82: 669–688
- Pearl J. 2000. Models, Reasoning and Inference. Cambridge, UK: Cambridge University Press. 379
- Peng C, Susan A. 2022. Stable learning establishes some common ground between causal inference and machine learning. *Nat Mach Intell*, 4: 110–115
- Penny G, Mondal M S, Biswas S, Bolster D, Tank J L, Müller M F. 2020. Using natural experiments and counterfactuals for causal assessment: River salinity and the Ganges Water agreement. *Water Resources Res*, 56, doi: 10.1029/2019WR026166
- Peters J, Janzing D, Schölkopf B. 2017. Elements of Causal Inference: Foundations and Learning Algorithms. Cambridge: The MIT Press. 288
- Quiroga R Q, Arnhold J, Grassberger P. 2000. Learning driver-response relationships from synchronization patterns. *Phys Rev E*, 61: 5142–5148
- Reich B J, Yang S, Guan Y, Giffin A B, Miller M J, Rappold A. 2021. A review of spatial causal inference methods for environmental and epidemiological applications. *Int Statistical Rev*, 89: 605–634
- Reichenbach H. 1956. The Direction of Time. Oakland: University of California Press. 280
- Reichstein M, Camps-Valls G, Stevens B, Jung M, Denzler J, Carvalhais N, Prabhat N. 2019. Deep learning and process understanding for data-driven Earth system science. *Nature*, 566: 195–204
- Rosenbaum P R, Rubin D B. 1983. The central role of the propensity score in observational studies for causal effects. *Biometrika*, 70: 41–55
- Rubin D B. 1974. Estimating causal effects of treatments in randomized and nonrandomized studies.. *J Educational Psychol*, 66: 688–701
- Rubin D B. 1980. Randomization analysis of experimental data: The fisher randomization test. *J Am Statistical Assoc*, 75: 575–582
- Runge J, Bathiany S, Bollt E, Camps-Valls G, Coumou D, Deyle E, Glymour C, Kretschmer M, Mahecha M D, Muñoz-Marí J, van Nes E H, Peters J, Quax R, Reichstein M, Scheffer M, Schölkopf B, Spirtes P, Sugihara G, Sun J, Zhang K, Zscheischler J. 2019a. Inferring causation from time series in Earth system sciences. *Nat Commun*, 10: 2553
- Runge J, Heitzig J, Petoukhov V, Kurths J. 2012. Escaping the curse of dimensionality in estimating multivariate transfer entropy. *Phys Rev Lett*, 108: 258701
- Runge J, Nowack P, Kretschmer M, Flaxman S, Sejdinovic D. 2019b. Detecting and quantifying causal associations in large nonlinear time series datasets. *Sci Adv*, 5: Eaa4996
- Runge J, Petoukhov V, Donges J F, Hlinka J, Jajcay N, Vejmelka M, Hartman D, Marwan N, Paluš M, Kurths J. 2015. Identifying causal gateways and mediators in complex spatio-temporal systems. *Nat Commun*, 6: 8502
- Runge J, Petoukhov V, Kurths J. 2014. Quantifying the strength and delay of climatic interactions: The ambiguities of cross correlation and a novel measure based on graphical models. *J Clim*, 27: 720–739
- Runge J. 2020. Discovering contemporaneous and lagged causal relations in autocorrelated nonlinear time series datasets. In: 36th Conference on Uncertainty in Artificial Intelligence (UAI)
- Sabine G H, Russell B. 1946. A history of western philosophy and its connection with political and social circumstances from the earliest times to the present day. *Am Historical Rev*, 51: 485–486
- Salvucci G D, Saleem J A, Kaufmann R. 2002. Investigating soil moisture feedbacks on precipitation with tests of Granger causality. *Adv Water Resources*, 25: 1305–1312
- Satake A, Leong Yao T, Kosugi Y, Chen Y Y. 2021. Testing the environmental prediction hypothesis for community-wide mass

- flowering in South-East Asia. *Biotropica*, 53: 608–618
- Schäck T, Muma M, Feng M, Guan C, Zoubir A M. 2018. Robust nonlinear causality analysis of nonstationary multivariate physiological time series. *IEEE Trans Biomed Eng*, 65: 1213–1225
- Schölkopf B, Locatello F, Bauer S, Ke N R, Kalchbrenner N, Goyal A, Bengio Y. 2021. Toward Causal Representation Learning. *Proc IEEE*, 109: 612–634
- Schölkopf B. 2022. Causality for Machine Learning. New York: Association for Computing Machinery. 765–804
- Schoolmaster Jr D R, Zirbel C R, Cronin J P. 2020. A graphical causal model for resolving species identity effects and biodiversity–ecosystem function correlations. *Ecology*, 101, doi: 10.1002/ecy.3070
- Schreiber T. 2000. Measuring information transfer. *Phys Rev Lett*, 85: 461–464
- Seth A K, Barrett A B, Barnett L. 2015. Granger causality analysis in neuroscience and neuroimaging. *J Neurosci*, 35: 3293–3297
- Shen Z, Cui P, Zhang T, Kunag K. 2020. Stable Learning via Sample Reweighting. New York: Proceedings of the AAAI Conference on Artificial Intelligence
- Shimizu S, Hoyer P O, Hyvärinen A, Kerminen A, Jordan M. 2006. A linear non-Gaussian acyclic model for causal discovery. *J Mach Learn Res*, 7: 2003–2030
- Shimizu S, Inazumi T, Sogawa Y, Hyvärinen A, Kawahara Y, Washio T, Hoyer P O, Bollen K. 2011. DirectLiNGAM: A direct method for learning a linear non-Gaussian structural equation model. *J Mach Learn Res*, 12: 1225–1248
- Silini R, Masoller C. 2021. Fast and effective pseudo transfer entropy for bivariate data-driven causal inference. *Sci Rep*, 11: 8423
- Smirnov D A. 2013. Spurious causalities with transfer entropy. *Phys Rev E*, 87: 042917
- Splawa-Neyman J, Dabrowska D M, Speed T P. 1990. On the application of probability theory to agricultural experiments. Essay on principles. Section 9. *Statist Sci*, 5, doi: 10.1214/ss/1177012031
- Steffen W, Richardson K, Rockström J, Schellnhuber H J, Dube O P, Dutreuil S, Lenton T M, Lubchenco J. 2020. The emergence and evolution of Earth System Science. *Nat Rev Earth Environ*, 1: 54–63
- Stocker T. 2014. Climate change 2013: The physical science basis. Working Group I Contribution to the Fifth Assessment Report of the Intergovernmental Panel on Climate Change. Cambridge: Cambridge Cambridge University Press. 1535
- Succi S, Coveney P V. 2019. Big data: The end of the scientific method? *Phil Trans R Soc A*, 377: 20180145
- Sugihara G, May R, Ye H, Hsieh C, Deyle E, Fogarty M, Munch S. 2012. Detecting causality in complex ecosystems. *Science*, 338: 496–500
- Takens F. 1981. Detecting Strange Attractors in Turbulence. Berlin: Springer. 366–381
- Taylor C M, de Jeu R A M, Guichard F, Harris P P, Dorigo W A. 2012. Afternoon rain more likely over drier soils. *Nature*, 489: 423–426
- Thulasiraman K, Swamy M N S. 2011. Graphs: Theory and Algorithms. Hoboken: John Wiley & Sons. 480
- Triacca U. 2005. Is Granger causality analysis appropriate to investigate the relationship between atmospheric concentration of carbon dioxide and global surface air temperature? *Theor Appl Climatol*, 81: 133–135
- Tuttle S E, Salvucci G D. 2017. Confounding factors in determining causal soil moisture-precipitation feedback. *Water Resources Res*, 53: 5531–5544
- van Nes E H, Scheffer M, Brovkin V, Lenton T M, Ye H, Deyle E, Sugihara G. 2015. Causal feedbacks in climate change. *Nat Clim Change*, 5: 445–448
- Vázquez-Patiño A, Campozano L, Mendoza D, Samaniego E. 2020. A causal flow approach for the evaluation of global climate models. *Int J Climatol*, 40: 4497–4517
- Verma T S, Pearl J. 2022. Equivalence and Synthesis of Causal Models. New York: Machinery. 221–236
- Vowels M J, Camgoz N C, Bowden R. 2021. D'ya like DAGs? A survey on structure learning and causal discovery. *ACM Comput Surv*, 55: 82
- Wei X, Huang S, Huang Q, Leng G, Wang H, He L, Zhao J, Liu D. 2021. Identification of the interactions and feedbacks among watershed water-energy balance dynamics, hydro-meteorological factors, and underlying surface characteristics. *Stoch Environ Res Risk Assess*, 35: 69–81
- Wiener N, Masani P. 1958. The prediction theory of multivariate stochastic processes, II: The linear predictor. *Acta Math*, 99: 93–137
- Williams B K, Brown E D. 2019. Sampling and analysis frameworks for inference in ecology. *Methods Ecol Evol*, 10: 1832–1842
- Yang J, Cushman S A, Song X, Yang J, Zhang P. 2015. Genetic diversity and drivers of genetic differentiation of *Reaumuria soongorica* of the Inner Mongolia plateau in China. *Plant Ecol*, 216: 925–937
- Yang M, Liu F, Chen Z, Shen X, Hao J, Wang J. 2021. CausalVAE: Disentangled representation learning via neural structural causal models. CVF Conference on Computer Vision and Pattern Recognition (CVPR)
- Yao L, Chu Z, Li S, Li Y, Gao J, Zhang A. 2021. A survey on causal inference. *ACM Trans Knowl Discov Data*, 15: 1–46

- Ye H, Deyle E R, Gilarranz L J, Sugihara G. 2015. Distinguishing time-delayed causal interactions using convergent cross mapping. *Sci Rep*, 5: 14750
- You Y, Liu J, Zhang Y, Beck H E, Gu X, Kong D. 2021. Impacts of El Niño-southern oscillation on global runoff: Characteristic signatures and potential mechanisms. *Hydro Process*, 35, doi: 10.1002/hyp.14367
- Yu Y, Chen J, Gao T, Yu M. 2019. DAG-GNN: DAG structure learning with graph neural networks. Long Beach: The 36th International Conference on Machine Learning
- Zhang K, Schölkopf B, Spirtes P, Glymour C. 2018. Learning causality and causality-related learning: Some recent progress. *Natl Sci Rev*, 5: 26–29
- Zhang Y J, Liu Z, Zhang H, Tan T D. 2014. The impact of economic growth, industrial structure and urbanization on carbon emission intensity in China. *Nat Hazards*, 73: 579–595
- Zheng X, Aragam B, Ravikumar P K, Xing E P. 2018. Dags with no tears: Continuous optimization for structure learning. Montréal. Adv Neural Inform Process Syst, 31, doi: 10.48550/arXiv.1803.01422

(责任编辑: 施建成)